



INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

BASE DE DATOS



***“EJERCICIO 3, LECTURA Y RESUMEN DE
TRES ARTÍCULOS”***

GRUPO: 3CV2

INTEGRANTES:

- *DANAET MONTSERRATH GONZÁLEZ
MARTÍNEZ*
- *GARCIA CASTILLO MARIO*
- *ISLAS RAMIREZ DIEGO*

PROFESOR: GABRIEL HURTADO AVILÉS

Contenido

ARTÍCULO 1. DATOS SÍSMICOS.....	2
ARTÍCULO 2. CONSUMO DE AGUA EN LA CIUDAD DE MÉXICO.	5
ARTÍCULO 3. OBRA PÚBLICA MUNICIPAL.	7
REFERENCIA BIBLIOGRÁFICA:	9

ARTÍCULO 1. DATOS SÍSMICOS.

“Cuando México tiembla: la historia contada por los datos”

El **problema** que aborda es la dificultad para comprender la información técnica sobre sismos en México que emite el Servicio Sismológico Nacional (SSN). Para resolverlo propone, un sitio web interactivo basado en software libre que transforma esos datos en visualizaciones, mapas y gráficos intuitivos, teniendo la opción de personalizarlos.

Importa porque México presenta en su 70% de su territorio riesgo sísmico. Aunque se tiene en cuenta que los sismos no se pueden predecir, este sistema prioriza básicamente el acceso a la información sin costos de licencias. Abarcando 3 áreas de mayor importancia:

- **En gestión gubernamental:** Permite relacionar zonas sísmicas con datos demográficos y económicos para la planeación territorial, rutas de evacuación y respuestas a emergencias.
- **En el ámbito de la educación y en la concientización pública:** Muestra a la población el riesgo latente en sus comunidades para arraigar una cultura de prevención; mediante mapas regionales.
- **En la investigación y estudio científico de los sismos:** Proporcionando a investigadores reportes que facilitan cálculos de inferencia sísmica, análisis de patrones y comparaciones de aumento o disminución en la actividad sísmica en los 125 años de registros.

El **origen** de los datos proviene de archivos en formato CSV descargados del sitio SSN (más de 300,000 sismos registrados desde 1900), y del INEGI (Censo de Población y Vivienda 2020 y Censos Económicos 2019).

Para poder usarlos se realizaron las siguientes 3 cosas:

1. **Limpieza y validación:** Se programó un script en Python que en pocas palabras se utilizó para detectar inconsistencias (campos vacíos, coordenadas inconsistentes o formatos incompatibles) y eliminar los registros inválidos.
2. **Modelado y almacenamiento:** El script generó código SQL para estructurar un almacén de datos (Data Warehouse) dentro del gestor de bases de datos PostgreSQL.

3. **Despliegue e interfaz:** Se desarrollaron servicios web usando PHP 9 y Apache. La interfaz de usuario se construyó con HTML5, CSS3, Bootstrap y JavaScript, integrando OpenStreetMap para la geolocalización precisa de los eventos.

La información se organizó bajo un modelo multidimensional de Data Warehouse:

- **Hechos (métricas cuantitativas):** Magnitud, profundidad y fecha/hora de los sismos; número de habitantes y datos de producción económica por zona.
- **Entidades/Dimensiones:** Dimensión geográfica/espacial (coordenadas, estados, municipios, localidades), dimensión temporal (años, meses) y dimensión socioeconómica (población e unidades económicas).
- **Relación:** Los sismos se vinculan geoespacialmente con las zonas demográficas y económicas, azul (poblaciones con 50 000 o más habitantes). Esto permite identificar la proximidad de los epicentros a localidades densamente pobladas o de alto valor productivo.
- **Clasificación por magnitud:** Verde, sismos de 2 a 3.9 grados; amarillo, de 4 a 5.9; rojo, de 6 o más.

Gracias a las diferentes vistas y reportes personalizados (que permiten filtrar por periodo de tiempo, magnitud, localidad, profundidad, número de habitantes o producción económica), **el sistema responde:**

1. **Riesgos en centros poblados:** ¿Qué localidades de más de 50,000 habitantes están cerca de los epicentros de sismos con magnitud de 2 grados o más?
2. **Análisis por región y tiempo:** ¿Cómo fue la actividad sísmica en un estado específico (ej. Jalisco en 2017) o para todo México en un año determinado?
3. **Alcance y afectación directa:** ¿Qué distancia alcanzó la onda sísmica y a qué localidades afectó directamente (mediante mapas de calor que mantienen la escala de colores por magnitud)?
4. **Reportes a medida:** ¿Cuál es el impacto sísmico en zonas con variables económicas o demográficas específicas?

Las limitaciones y despliegue en la implementación e instalación del sistema podía resultar complicada para usuarios con poco dominio técnico. Para resolverlo, se empaquetó en **Docker Compose** dividiendo el sistema en dos contenedores

interconectados (uno para la base de datos PostgreSQL y otro para el servidor web PHP). Su distribución se realiza libremente mediante un repositorio público en GitHub.

Hablando de un **trabajo futuro se proponen:**

1. Habilitar **visualizaciones** en 3D.
2. Incorporar un mayor número de **fuentes de datos oficiales**.
3. Integrar el sistema con **plataformas de alerta temprana**.

ARTÍCULO 2. CONSUMO DE AGUA EN LA CIUDAD DE MÉXICO.

“Territorial Information Retrieval from Heterogeneous Open Data through the Construction of a Data Warehouse for Water Management in Mexico City”

El **problema** que nos presenta este artículo es la crisis de agua por la sobreexplotación de acuíferos, fugas en la red y el crecimiento poblacional en la ciudad de México. Aunque existen datos abiertos sobre consumo de agua publicados por SACMEX están en formatos poco accesibles y sin herramientas de consulta, lo que limita su uso para la toma de decisiones basada en evidencia, también se aborda como recuperar información territorial útil a partir de esos datos dispersos, tanto para los ciudadanos que consultan su colonia, así como para servidores públicos, investigadores y periodistas.

Los **datos provienen** del recurso oficial 'Consumo Agua (1er Semestre 2019)' de SACMEX, publicado en el Portal de Datos Abiertos de la CDMX en formato CSV, y cubren solo los primeros tres bimestres de 2019 (71,102 registros). Se complementaron con una serie climática de Open-Meteo y cartografía base de OpenStreetMap.

Para poder usarlos se realizaron las siguientes 2 cosas:

- **Validación y limpieza:** se descartaron 216 registros (0.30%) por no poder resolver su etiqueta territorial.
- **Carga final:** 70,886 registros quedaron cargados con éxito en el almacén de datos.

La información se organizó en un esquema con las siguientes características:

- **Esquema:** en estrella, con dos tablas de hechos — fact_consumo_agua y fact_clima.
- **Dimensiones:** dim_tiempo (fecha, año, bimestre), dim_ubicacion (alcaldía, colonia, coordenadas) y dim_indice_des (nivel de desarrollo).
- **Extensión:** el esquema se republicó como grafo de conocimiento RDF (R2RML), con adyacencia territorial propia entre colonias.

Gracias a esta recopilación de información nos permite responder a las preguntas

- **¿Cuánto se consume por colonia o alcaldía, filtrando por año y bimestre?**
- **¿Qué alcaldías consumen más? (ej. Cuauhtémoc y Miguel Hidalgo)**
- **¿Qué colonias tienen consumo atípico respecto a las demás de su alcaldía?**

Las **limitaciones** en este artículo son el periodo cubierto solo es un semestre de 2019, por lo que la variación estacional observada es una comparación dentro del semestre y no permite establecer una relación causal con temporada de lluvias o secas. El módulo de detección de consumo atípico es exploratorio y se evaluó únicamente con perturbaciones sintéticas, no con fugas reales. La geometría usa centroides en vez de polígonos oficiales, por lo que la 'adyacencia' es proximidad y no colindancia real.

Como trabajo futuro proponen materializar el grafo en un triple store persistente con endpoint SPARQL público, sustituir los centroides por polígonos oficiales, alinear los identificadores territoriales con autoridades externas, reevaluar el módulo de anomalías con datos etiquetados reales, y transferir el método a otros dominios de datos abiertos urbanos (movilidad, calidad del aire, riesgo sísmico). En resumen:

- **Materializar** el grafo en un triple store con endpoint SPARQL público.
- **Sustituir** centroides por polígonos oficiales y alinear identificadores territoriales.
- **Transferir** el método a otros dominios (movilidad, calidad del aire, riesgo sísmico).

ARTÍCULO 3. OBRA PÚBLICA MUNICIPAL.

"A Dimensional Data Warehouse for Geospatial Monitoring of Municipal Public Works, with an Evolution Path Toward a Lakehouse Architecture"

El **problema** se basa en el crecimiento acelerado de datos sobre infraestructura pública municipal que genera volúmenes heterogéneos y fragmentados. Por lo general, los municipios operan con hojas de cálculo aisladas o sistemas transaccionales distribuidos que impiden realizar análisis históricos, detectar retrasos de forma temprana y ofrecer una verdadera participación ciudadana, esto afectando la rendición de cuentas y el uso eficiente del presupuesto público.

Los **datos** son concisos, resumiéndolo en un generador con semilla que simula 1,247 obras públicas de 55 comunidades del municipio de Temascaltepec, Estado de México (\$127.4 M de presupuesto acumulado), debido a restricciones de privacidad sobre registros reales, y nos genera:

- **Datos estructurados:** texto, coordenadas y montos capturados vía una API REST (Flask).
- **Evidencia no estructurada:** fotografías y PDF almacenados en Cloudflare R2.
- **Sincronización:** el almacén se puebla mediante disparadores (triggers) de base de datos, no un ETL externo.

La **información se organizó** en un esquema con dos tablas de hechos y Seis vistas analíticas derivadas exponen obras retrasadas, alertas de auditoría, trazabilidad histórica, participación ciudadana, ejecución presupuestal y detección de anomalías mediante tres criterios (costo atípico, retraso mayor a 120 días, e inconsistencia entre avance físico y financiero). Con las siguientes características:

- **Hechos:** fact_audit_events (un evento de auditoría) y fact_work_monthly (una obra por mes).
- **Dimensiones** tipo 2 (con historial): dim_work, dim_region, dim_company, dim_staff, dim_budget.
- **Dimensiones** tipo 1 y catálogos: dim_source, dim_citizen, dim_proposal, dim_time, dim_event_type.

El sistema permite saber qué obras están retrasadas, qué alertas de auditoría se han generado, cómo se ha ejecutado el presupuesto acumulado y qué combinaciones de obra-mes son estadísticamente anómalas según los tres criterios definidos, apoyando la inspección prioritaria.

- **¿Qué obras están retrasadas y por cuántos días?**
- **¿Cuál era el estado exacto de una obra en una fecha pasada (presupuesto, contratista)?**
- **¿Cómo se ha ejecutado el presupuesto por fuente de financiamiento?**
- **¿Qué obras-mes son estadísticamente anómalas y deben inspeccionarse primero?**

Las **limitaciones** radican en que los autores reconocen que no existe un despliegue dinámico alojado de forma permanente, que el esquema de votación puede no representar adecuadamente a las minorías, y que la calidad del análisis depende enteramente de lo que capturan los supervisores de campo. El almacén de objetos todavía no es un lago de datos consultable, solo un repositorio de evidencia binaria, y el control de acceso es ligero. Además, la regla de detección de anomalías no supera a un Isolation Forest no supervisado en las métricas de área bajo la curva, y falla especialmente en detectar sobreprecios y pagos adelantados al avance físico.

Como **trabajo futuro** proponen evolucionar hacia un lakehouse completo con un formato de tabla abierto (Iceberg/Parquet) consultable directamente sobre el almacén de objetos; un pipeline de visión por computadora para clasificar el avance de obra a partir de fotografías; publicar el esquema como vocabulario OWL y una proyección conforme al estándar OC4IDS; voto cuadrático para mejorar la representatividad; modelos de series de tiempo para predecir fechas de conclusión; recalculer el criterio de anomalía de costos por tipo de obra; y validar la arquitectura en municipios adicionales.

- **Evolucionar** hacia un lakehouse completo (Iceberg/Parquet) consultable sobre el objeto-almacén.
- **Visión** por computadora para clasificar avance de obra desde fotografías.
- **Publicar** el esquema como vocabulario OWL y validar la arquitectura en más municipios.

REFERENCIA BIBLIOGRÁFICA:

Villa Vargas, J. M., Hurtado Avilés, G., y Climent Hernández, J. A. (2026). Cuando México tiembla: la historia contada por los datos. *AZCATL Revista de Divulgación de la Ciencia, la Ingeniería y la Innovación*, 4(6), 28–33.

<https://doi.org/10.24275/AZC2026E1004>

Velázquez Arrieta, E. U., Pulido Morales, O. F., García López, E., Hernández Martínez, C. A., y Hurtado Avilés, G. (en prensa). Territorial information retrieval from heterogeneous open data through the construction of a data warehouse for water management in Mexico City. En *Advances in Computer Science Applications and Research*. Springer.

González Casiano, U., Maldonado Mejía, M. T., y Hurtado Avilés, G. (en prensa). A dimensional data warehouse for geospatial monitoring of municipal public works, with an evolution path toward a lakehouse architecture. En *Advances in Computer Science Applications and Research*. Springer.